

Predicción del Customer Lifetime Value en Seguros Automotrices mediante Modelos de Ensemble

LABORATORIO DE APRENDIZAJE ESTADÍSTICO

JULIETA MADRIGAL FLORES

GIBRÁN LEONARDO CHÁVEZ GONZÁLEZ

DIANA FERNANDA BARBOSA DUEÑAS

OBJETIVOS

General

Predecir el valor de vida del cliente (Customer Lifetime Value) en una cartera de seguros automotrices mediante la implementación y comparación de modelos de ensamble de machine learning, a partir del análisis de variables demográficas, de comportamiento y de póliza.

Específico


- Analizar el dataset IBM Watson Marketing Customer Value
- Diseñar e implementar un pipeline de preprocesamiento y modelado que integre de forma sistemática la transformación de variables, el entrenamiento de modelos y su evaluación.
- Evaluar si la interacción entre Income y Total Claim Amount es estadísticamente significativa mediante ANOVA para justificar su incorporación como variable derivada en el pipeline.
- Ajustar un modelo de Random Forest con optimización bayesiana de hiperparámetros para predecir el Customer Lifetime Value.
- Ajustar un modelo de XGBoost con optimización bayesiana de hiperparámetros bajo las mismas condiciones experimentales que Random Forest.
- Comparar el desempeño predictivo de ambos modelos mediante validación cruzada RepeatedKFold, reportando media y desviación estándar del RMSE.
- Determinar qué modelo predice con mayor precisión el CLV y qué variables resultan más influyentes.

DATASET & EDA




	Customer	State	Customer Lifetime Value	Response	Coverage	Education	Effective To Date	EmploymentStatus	Gender	Income	...
0	BU79786	Washington	2763.519279	No	Basic	Bachelor	2/24/11	Employed	F	56274	...
1	QZ44356	Arizona	6979.535903	No	Extended	Bachelor	1/31/11	Unemployed	F	0	...
2	AI49188	Nevada	12887.431650	No	Premium	Bachelor	2/19/11	Employed	F	48767	...
3	WW63253	California	7645.861827	No	Basic	Bachelor	1/20/11	Unemployed	M	0	...

...	Months Since Policy Inception	Number of Open Complaints	Number of Policies	Policy Type	Policy	Renew Offer Type	Sales Channel	Total Claim Amount	Vehicle Class	Vehicle Size
...	5	0	1	Corporate Auto	Corporate L3	Offer1	Agent	384.811147	Two-Door Car	Medsize
...	42	0	8	Personal Auto	Personal L3	Offer3	Agent	1131.464935	Four-Door Car	Medsize
...	38	0	2	Personal Auto	Personal L3	Offer1	Agent	566.472247	Two-Door Car	Medsize
...	65	0	7	Corporate Auto	Corporate L2	Offer1	Call Center	529.881344	SUV	Medsize

PIPELINE



TRANSFORMACIÓN DEL TARGET CLV



H I P E R P A R Á M E T R O S

M O D E L O 1 - R A N D O M F O R E S T R E G R E S S O R

Número de árboles

Máxima profundidad de cada árbol

Máximo de hijas finales por árbol

Proporción de variables usadas en cada árbol

M O D E L O 2 — X G B O O S T R E G R E S S O R

Número de árboles

Máxima profundidad de cada árbol



Máximo de hojas por árbol

Mejor mínima para una nueva división

Regularización L1



Regularización L2

TRAIN




Modelo	RMSE	R^2
Random Forest	2172.072216	0.876641
XGBoost	1863.619812	0.909189

TEST



Modelo	RMSE	R^2
Random Forest	3337.595300	0.737550
XGBoost	3434.912537	0.722022

RESULTADOS



CONCLUSIONES

- Random Forest y XGBoost fueron optimizados con búsqueda bayesiana sobre espacios amplios de hiperparámetros, utilizando RepeatedKFold (5 splits, 4 repeticiones) como esquema de validación. Ambos modelos aplicaron transformación logarítmica sobre el target mediante TransformedTargetRegressor para estabilizar la distribución del CLV.
- El ANOVA confirmó que la interacción entre Income y Total Claim Amount es estadísticamente significativa ($p = 0.0137 < 0.05$), lo que justifica su inclusión como variable derivada en el pipeline mediante PolynomialFeatures.
- Random Forest generalizó mejor sobre datos no vistos, obteniendo un RMSE promedio en validación cruzada menor a XGBoost. En test, Random Forest alcanzó un RMSE de 3,337 y un R^2 de 0.738, superando a XGBoost (RMSE 3,434, R^2 0.72). Aunque XGBoost mostró mejor ajuste en entrenamiento, esto evidenció mayor sobreajuste.
- Las variables más influyentes en la predicción del CLV corresponden a características de la póliza como Monthly Premium Auto y Number of Policies, lo cual es consistente con la lógica del negocio: los clientes con primas más altas y mayor número de pólizas contratadas tienden a generar mayor valor para la aseguradora.

¡MUCHAS GRACIAS!